



BENEMÉRITA UNIVERSIDAD
AUTÓNOMA DE PUEBLA

FACULTAD DE CIENCIAS FÍSICO MATEMÁTICAS
LICENCIATURA EN ACTUARÍA

ECONOMETRÍA

Determinantes socioeconómicos de la Pobreza
Municipal en México, 2020

Alumnos:

Díaz Durán Ariadna, González Islas Samuel
Mariscal Armenta Luis A., Morales Solís Ismael
Sánchez Luna Alejandra, Vázquez Alavez Maryangel

Profesora:

Rosalba Mercado Ortiz

Los Mínimos Cuadrados

16 de mayo de 2026

Índice

1. Introducción	3
1.1. Antecedentes	3
1.2. Contexto y motivación económica	3
2. Pregunta de investigación y objetivos	4
2.1. Pregunta de investigación	4
2.2. Objetivo general	4
2.3. Objetivos específicos	4
3. Marco teórico	4
4. Hipótesis	5
4.1. Hipótesis general	5
4.2. Hipótesis individuales	5
5. Datos	5
5.1. Fuente y Descripción de la Base de Datos	5
5.2. Procesamiento y Limpieza de Datos	6
5.3. Diccionario de Variables	6
5.4. Análisis Exploratorio y Tratamiento	7
6. Metodología	7
6.1. Modelo Base	7
6.1.1. Verificación de los supuestos	8
6.2. Modelos Alternativos	9
6.3. Supuestos y estrategias de identificación	11
7. Resultados	11
7.1. Interpretación económica	11
8. Validación y diagnóstico	12
8.1. Outliners	12
8.2. Sensibilidad	13
8.3. VIF	13
8.4. Transformaciones	13
8.5. Normalidad de los residuos	14
8.6. Heteroscedasticidad	14
9. Modelo final	14
10. Conclusión	15
10.1. Hallazgos clave	15
10.2. Implicaciones económicas/financieras	15
10.3. Limitaciones del análisis	16
11. Referencias	16
12. Anexos	16

1. Introducción

1.1. Antecedentes

La primera fase de este proyecto se centró en el análisis del Rendimiento Académico Universitario” mediante modelos econométricos basados en encuestas digitales aplicadas a estudiantes. A pesar de incrementar la muestra de 151 a 337 observaciones tras una segunda emisión del cuestionario, los resultados evidenciaron serios problemas estructurales y de especificación. El principal inconveniente radica en la baja capacidad explicativa del modelo. El coeficiente de determinación R^2 alcanzó apenas un 0.018, indicando que menos del 2 % de la variabilidad del promedio académico es explicada por las variables independientes incluidas. El desglose completo de las estimaciones y pruebas individuales de esta etapa se puede consultar en el (Anexo 1)

Asimismo, la prueba F global no resultó estadísticamente significativa, lo que invalida la hipótesis general del proyecto al no existir evidencia conjunta de que las variables explicativas afecten al rendimiento académico. A nivel individual, la mayoría de los regresores (como estrés, horas de sueño, redes sociales o trabajo) carecen de significancia estadística; únicamente las variables "Horas de estudio" y "Tiempo de traslado" mostraron significancia en la primera etapa, pero la perdieron por completo al consolidar la muestra final.

Adicionalmente, la prueba de Shapiro-Wilk rechazó la normalidad de los residuos, afectando la confiabilidad de los intervalos de confianza. La aplicación de transformaciones funcionales como Box-Cox y modelos log-lineales no generó mejoras significativas.

Como una solución alternativa se realizaron diferentes modelos de regresión con variables académicas, personales, familiares y socioeconómicas que se incluyeron basándonos en la información teórica, donde nos dice que el desempeño escolar no depende únicamente de las capacidades del estudiante, sino también de factores asociados al entorno familiar, las condiciones económicas, los hábitos de estudio y el contexto educativo; sin embargo, no se llegó a una solución de forma exitosa, ya que los estadísticos seguían siendo malos para explicar nuestra variable dependiente (Anexo 2), aun así, haciendo las comparaciones pertinentes, nuestro mejor modelo era el de "Variables familiares y socioeconómicas", al cual le realizamos diferentes transformaciones, resolviendo problemas como heteroscedasticidad y de especificación con la transformación Box-Cox, pero aún sin éxito en los estadísticos. Esto demuestra que el problema no deriva de la forma funcional, sino de las limitaciones intrínsecas de la base de datos, caracterizada por variables subjetivas, perceptuales y propensas a sesgos de medición. Por consiguiente, para evitar conclusiones econométricas débiles, se decidió reestructurar el trabajo y cambiar el enfoque hacia el estudio de los determinantes socioeconómicos de la pobreza municipal en México, lo cual ofrece un marco teórico más robusto, mayor objetividad de los datos y viabilidad para diagnósticos econométricos completos.

1.2. Contexto y motivación económica

Al cambiar de tema, nuestro análisis ahora se enfoca en la pobreza a nivel municipal utilizando los datos oficiales del CONEVAL y del CONAPO, que abarcan los municipios del país. Analizar la pobreza a esta escala es de suma importancia ya que el municipio es el gobierno más cercano a la gente y es donde se ven reflejadas las carencias sociales y la marginación de forma directa.

Los datos oficiales nos muestran que México es un país de enormes contrastes y que la pobreza no se comporta igual en todos lados. Por un lado, en los últimos años, la mayoría de los municipios lograron reducir sus niveles de pobreza. Sin embargo, en cientos de municipios la situación empeoró y la pobreza aumentó.

Además, la brecha entre regiones es gigantesca. Mientras existen zonas urbanas o comerciales donde la pobreza afecta a menos del 10 % de la población, en los municipios más vulnerables, principalmente zonas indígenas de estados como Chiapas, Oaxaca y Guerrero, la pobreza llega a golpear a más del 95 % de sus habitantes. Esta gran diferencia demuestra que la pobreza y la marginación dependen del lugar donde se nace y se vive, lo que nos permite estudiarlas a fondo combinando estas bases de datos y así aplicar un modelo econométrico.

Desde el lado de la economía, entender qué causa la pobreza en los municipios es fundamental si se quieren diseñar programas sociales que de verdad funcionen y repartir mejor el presupuesto público. Como el CONEVAL mide la pobreza de forma multidimensional, sabemos que este problema no es solo la falta de dinero; sino que esta relacionado a seis carencias sociales clave: el rezago educativo, la falta de acceso a la salud, la falta de seguridad social, las malas condiciones de la vivienda, la escasez de servicios básicos (como agua o luz) y la mala alimentación.

La motivación de esta segunda fase es usar un modelo de regresión para aislar y medir qué tanto influyen estas carencias en el porcentaje de pobreza de cada municipio. Con esto, queremos encontrar un modelo fuerte que nos diga qué fallas en la educación o en la infraestructura están atrapando a los municipios en la pobreza.

2. Pregunta de investigación y objetivos

El análisis de los determinantes socioeconómicos de la Pobreza Municipal en México es el tema que optamos para su estudio ya que buscamos comprender los factores que influyen para considerar a un municipio como el más pobre del país. Bajo este contexto, usaremos el modelo de regresión múltiple que nos permite identificar relaciones significativas entre diversas variables explicativas y una variable dependiente que represente el porcentaje de pobreza. Durante el presente proyecto queremos buscar y analizar la existencia de relaciones entre un conjunto de variables obtenidas a partir de las bases de datos que proporcionan la CONEVAL y la CONAPO para los años 2020.

2.1. Pregunta de investigación

¿Cuáles son los principales determinantes sociodemográficos, educativos y de infraestructura habitacional que explican la variación en el porcentaje de pobreza en México?

2.2. Objetivo general

Determinar y cuantificar el impacto de los factores educativos, laborales y de infraestructura habitacional sobre el porcentaje de pobreza a nivel municipal en México.

2.3. Objetivos específicos

- Caracterizar estadísticamente la distribución de la pobreza municipal en México y sus variables explicativas asociadas al rezago social y laboral.
- Estimar el modelo de regresión múltiple utilizando el porcentaje de pobreza municipal como variable dependiente, y variables sociodemográficas clave como el analfabetismo, población con ingresos bajos y otras como variables independientes.
- • Evaluar el cumplimiento de los supuestos clásicos de la regresión como ausencia de multicolinealidad mediante el factor de inflación de la varianza (VIF), homocedasticidad mediante la prueba de White o Breusch-Pagan, y correcta especificación funcional.
- Interpretar los coeficientes económicos obtenidos para identificar qué factores tienen un mayor impacto marginal en el nivel de pobreza en México.

3. Marco teórico

La variable que buscamos explicar en este modelo es el porcentaje de pobreza en México. La pobreza es un fenómeno multidimensional que no solamente depende del nivel de ingresos de la población, sino también de las condiciones educativas, de vivienda y acceso a servicios básicos. Organismos como el CONEVAL señalan que factores relacionados con el rezago social y las condiciones de vida tienen una relación directa con los niveles de pobreza. **coneval2020rezago**

En primer lugar, el analfabetismo representa una limitante importante para el desarrollo económico y social de la población. Diversos estudios muestran que menores niveles educativos reducen las oportunidades laborales y los ingresos de las personas, por lo que municipios con mayores niveles de analfabetismo tienden a presentar mayores niveles de pobreza.

Asimismo, las condiciones de vivienda son un elemento fundamental para medir el bienestar social. Variables como la carencia de servicios básicos en la vivienda, el hacinamiento y la sobreocupación reflejan deficiencias estructurales que suelen presentarse en zonas con altos niveles de marginación. De igual manera, el porcentaje de viviendas con piso de tierra se relaciona con menores condiciones de calidad de vida y con mayores niveles de rezago social. **villanueva2021persiste**

Por otro lado, el porcentaje de población ocupada con ingresos de hasta dos salarios mínimos es un indicador relacionado con la insuficiencia de ingresos. Aun cuando las personas formen parte de la población ocupada, bajos niveles salariales limitan el acceso a bienes y servicios básicos, lo cual incrementa la probabilidad de encontrarse en situación de pobreza. Igualmente, el tamaño de la localidad puede influir significativamente en las condiciones socioeconómicas de la población. Las localidades con menos de 5,000 habitantes suelen presentar menor acceso a infraestructura, servicios públicos, educación y oportunidades laborales, por lo que se espera una mayor incidencia de pobreza en estas zonas.

Finalmente, el grado de marginación se incorpora mediante variables categóricas, ya que permite clasificar a los municipios según sus niveles de rezago social y carencias estructurales. En general, municipios con grados de marginación más altos tienden a presentar mayores porcentajes de pobreza.

4. Hipótesis

4.1. Hipótesis general

La hipótesis general que buscamos probar es que todos los factores sociodemográficos que consideramos explican el modelo de manera significativa el porcentaje de pobreza, es decir:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0 \quad vs \quad H_1 : \exists \beta_k \neq 0$$

4.2. Hipótesis individuales

Por otro lado, las hipótesis individuales que deseamos probar sobre el efecto de las variables explicativas en la pobreza son las siguientes:

- Se espera que el analfabetismo tenga un efecto positivo sobre el porcentaje de pobreza, ya que menores niveles educativos reducen las oportunidades económicas de la población.
- Esperamos que las variables relacionadas con carencias en la vivienda, como servicios básicos insuficientes, hacinamiento, sobreocupación y viviendas con piso de tierra, tengan un efecto positivo debido a que reflejan condiciones de rezago social.
- Asimismo, se espera que la población ocupada con ingresos de hasta dos salarios mínimos tenga una relación positiva con la pobreza, ya que bajos niveles salariales limitan el acceso a mejores condiciones de vida.
- También se espera que las localidades menores a 5,000 habitantes presenten mayores niveles de pobreza debido al menor acceso a infraestructura y oportunidades económicas.

5. Datos

5.1. Fuente y Descripción de la Base de Datos

Para realizar el análisis de los determinantes de la pobreza municipal, combinamos dos fuentes de información oficiales y de acceso público, obtenidas a través de la Plataforma Nacional de Datos Abiertos:

- Base de Datos de Pobreza Municipal (CONEVAL): Se utilizó el concentrado histórico de indicadores de pobreza multidimensional a nivel municipal (desagregado por año y sexo). Estos datos corresponden a las estimaciones oficiales de los años 2010, 2015 y 2020, calculadas bajo los lineamientos institucionales del CONEVAL.
- Indicadores de Marginación 2020 (CONAPO): Se descargó la base que contiene las variables socioeconómicas y estructurales utilizadas para construir el Índice de Marginación más reciente.

Ambas bases de datos originales cubren el total de los 2,466 municipios que integran el territorio mexicano, lo que garantiza que el modelo trabaje con todas las observaciones.

5.2. Procesamiento y Limpieza de Datos

Para construir la base de datos final del modelo de regresión múltiple, realizamos un proceso de consolidación y limpieza mediante los siguientes pasos:

- **Filtro Temporal:** Como primer paso, filtramos la base del CONEVAL para trabajar únicamente con los datos correspondientes al año 2020. De esta manera, alineamos la información temporal con la base de la CONAPO (que también corresponde a 2020), asegurando un análisis de corte transversal.
- **Concatenación por Clave Municipal:** Unimos ambas bases de datos asegurando la correspondencia exacta de la información de cada municipio. Para ello, utilizamos como identificador único la Clave Municipal.^a signada institucionalmente, lo que evitó errores de duplicidad o registros mal cruzados.
- **Creación de Variables Dummies para la Marginación:** La variable original del grado de marginación (*GMM2020*) venía expresada de forma cualitativa con cinco niveles: Muy bajo, Bajo, Medio, Alto y Muy alto. Para poder incluir esta información en el modelo de regresión, transformamos cada uno de estos niveles en variables o dummies con valores de 0 o 1. De esta forma, si un municipio pertenece a una categoría, su variable dummy toma el valor de 1 y las demás se mantienen en 0, permitiendo capturar el efecto específico de cada nivel de rezago sobre la pobreza.
- **Depuración de Variables:** Una vez unidas las bases, eliminamos las columnas de texto e identificación que no aportaban valor numérico al análisis, como los nombres de los estados, nombres de los municipios y las propias claves geográficas. De esta manera, limpiamos la matriz de datos para conservar estrictamente las variables cuantitativas y categóricas que se evaluarán como determinantes en el modelo econométrico.

5.3. Diccionario de Variables

Ya que la base de datos que construimos cuenta con 50 variables e indicadores, solo presentamos el diccionario de las variables que utilizamos para obtener el mejor modelo econométrico.

Nombre	Tipo	Rol en el modelo	Descripción
Pobreza_porcentaje	Continua	Variable dependiente	Representa el porcentaje de la población municipal en situación de pobreza.
ANALF	Continua	Variable independiente (X_1)	Porcentaje de población de 15 años o más analfabeta.
SBASC	Continua	Variable independiente (X_2)	Porcentaje de población de 15 años o más sin educación básica.
OVSDE	Continua	Variable independiente (X_3)	Porcentaje de ocupantes en viviendas particulares habitadas sin drenaje ni excusado.
VHAC	Continua	Variable independiente (X_4)	Porcentaje de viviendas particulares con hacinamiento.
OVPT	Continua	Variable independiente (X_5)	Porcentaje de ocupantes en viviendas particulares con piso de tierra.
PO2SM	Continua	Variable independiente (X_6)	Porcentaje de población ocupada con ingresos de hasta 2 salarios mínimos.
PL.5000	Continua	Variable independiente (X_7)	Porcentaje de población que vive en localidades menores a 5000 habitantes.
GM_Medio	Dummy	Variable independiente (X_8)	Grado de marginación medio.
GM_Alto	Dummy	Variable independiente (X_9)	Grado de marginación alto.
GM_Muy alto	Dummy	Variable independiente (X_{10})	Grado de marginación muy alto.
GM_Bajo	Dummy	Variable independiente (X_{11})	Grado de marginación bajo.

Tabla 1: Definición de Variables del Modelo

5.4. Análisis Exploratorio y Tratamiento

Una vez estructurada la base de datos limpia con las 50 variables finales, ejecutamos una etapa de análisis exploratorio en Python para garantizar que tengamos información completa antes de estimar el modelo:

- Verificación de Valores Faltantes y Estructura: Mediante el comando `.info()`, revisamos que todas las columnas estuvieran en el formato numérico adecuado `float64` o `int64`. Asimismo, verificamos que la base no contuviera valores faltantes `nulls` o `NaNs`, asegurando que los 2,466 municipios tuvieran registros completos para todas las variables y evitar sesgos por pérdida de observaciones.
- Análisis Estadístico Descriptivo: Utilizamos la función `.describe()` para obtener un resumen estadístico detallado de la muestra. Evaluamos las medidas de tendencia central y de dispersión como medias, desviaciones estándar, valores mínimos y máximos tanto de la variable dependiente de pobreza como de los regresores socioeconómicos. Esto nos permitió validar las escalas de medición de cada variable y descartar anomalías en los datos.
- Análisis de Correlación y Dispersión: Calculamos la matriz de correlación entre todas las variables con el fin de tener un primer diagnóstico visual sobre cómo interactúan los determinantes con el porcentaje de pobreza. Este paso fue fundamental para detectar posibles problemas de multicolinealidad y analizar las relaciones lineales iniciales mediante diagramas de dispersión, lo cual sirvió de sustento para formular nuestras hipótesis de signos esperados.

Al revisar los valores máximos y mínimos en las estadísticas descriptivas, se identificó la presencia de valores atípicos en los extremos de las distribuciones de las variables que podían sesgar los coeficientes estimados. Para solucionar esto, aplicamos el método de percentiles de forma independiente en cada modelo. Establecimos umbrales críticos en los percentiles extremos de la distribución para identificar y recortar aquellas observaciones con comportamientos excesivamente atípicos. Esto nos permitió limpiar la muestra estadísticamente sin incurrir en sesgos.

6. Metodología

Para obtener un modelo óptimo, se utilizaron diversas herramientas econométricas implementadas en Python. En una primera etapa, se aplicó el método de selección Stepwise con el objetivo de identificar las variables más relevantes para el modelo.

Posteriormente, se propusieron cuatro modelos alternativos estimados mediante el método de Mínimos Cuadrados Ordinarios (MCO).

Una vez estimados, se realizó la verificación de los supuestos clásicos de regresión en cada modelo, detectándose problemas relacionados con la forma funcional y la presencia de heterocedasticidad. Para corregir estas inconsistencias, se implementaron distintas transformaciones, como la Box-Cox y modelos log-lineales, además de técnicas de estimación robusta. En particular, se emplearon Mínimos Cuadrados Ponderados (WLS) y errores estándar robustos tipo HC3, con el fin de obtener estimaciones más eficientes y estadísticamente confiables. A continuación, se presenta el desarrollo detallado de cada una de estas etapas.

6.1. Modelo Base

Con el objetivo de evaluar el efecto de los distintos factores socioeconómicos sobre la pobreza a nivel municipal, se plantea inicialmente un modelo de regresión lineal múltiple de corte transversal para el año 2020. La selección de las variables explicativas responde a la necesidad de medir la marginación social, por medio del conjunto de rezagos y desventajas estructurales que afectan a una población en como educación, vivienda, distribución territorial de la población e ingresos.

Estas variables resultan particularmente relevantes debido a que la marginación constituye uno de los principales determinantes de la pobreza multidimensional. En este sentido, su incorporación al modelo permite capturar las condiciones estructurales que generan exclusión social y limitan el acceso de la población a derechos y oportunidades básicas. Por ello, desde una perspectiva econométrica, este conjunto de indicadores proporciona una base adecuada para explicar las diferencias en los niveles de pobreza entre municipios.

Bajo este enfoque, el modelo base de la investigación es el siguiente:

$$\text{Pobreza} = \beta_0 + \beta_1(\text{ANALF}) + \beta_2(\text{SBASC}) + \beta_3(\text{OVSDE}) + \beta_4(\text{VHAC}) + \beta_5(\text{OVPT}) + \beta_6(\text{PO2SM}) + \beta_7(\text{PL.5000}) \\ + \beta_8\mathbb{I}(\text{GM} = \text{Alto}) + \beta_9\mathbb{I}(\text{GM} = \text{Medio}) + \beta_{10}\mathbb{I}(\text{GM} = \text{Muy alto}) + \beta_{11}\mathbb{I}(\text{GM} = \text{Bajo}) + \varepsilon$$

La justificación teórica y económica para la inclusión de cada una de estas variables independientes en el modelo base se detalla a continuación:

- Educación (ANALF y SBASC): El rezago educativo es una de las carencias sociales más importantes. La falta de alfabetización y de educación básica limita el acceso a empleos formales, bien remunerados y con seguridad social. Estas variables explican la trampa intergeneracional de la pobreza: A menor preparación, menores ingresos futuros.
- Vivienda (OVSPS, VHAC, OVSDE y OVSAE): El piso de tierra es históricamente uno de los indicadores más robustos y sensibles de la pobreza extrema en México, estando directamente asociado con problemas de salud insalubre y una falta severa de inversión patrimonial.

El hacinamiento refleja la incapacidad económica de los hogares para expandir su vivienda conforme crece la familia, afectando discretamente la calidad de vida y la privacidad.

La carencia de drenaje y agua entubada miden la infraestructura pública y el bienestar sanitario. Al no depender del ingreso del individuo sino de la inversión del Estado, son indicadores puros de Pobreza estructuralrural y periurbana.

- Distribución de la Población (PL.5000): Esta variable capta la dispersión poblacional en México. Las localidades rurales de menos de 5,000 habitantes sufren de altos costos de transporte, falta de mercados competitivos y difícil acceso a clínicas y escuelas de nivel medio-superior, existiendo una correlación histórica altísima entre ruralidad y pobreza.
- Ingresos (PO2sm): El ingreso es el eje económico de la pobreza. En México, percibir dos salarios mínimos o menos para una familia promedio condena al hogar a mantenerse por debajo de la canasta alimentaria y no alimentaria, capturando la precarización laboral y el peso de la economía informal.
- Marginación (GM.Bajo, GM.Medio, GM.Alto y GM.Muy Alto): Estas variables absorben el impacto de la exclusión social regional. Al segmentar el Grado de Marginación en variables dicotómicas, el modelo no solo analiza los factores individuales del hogar, sino que pondera el entorno socioeconómico general de la región donde viven.

6.1.1. Verificación de los supuestos

Después de estimar el modelo base, se realizaron distintas pruebas de diagnóstico con el objetivo de verificar el cumplimiento de los principales supuestos de la regresión lineal múltiple. En particular, se aplicó la prueba de Shapiro-Wilk para evaluar la normalidad de los residuos, la prueba de Breusch-Pagan para analizar la presencia de heterocedasticidad, el cálculo del Factor de Inflación de la Varianza (VIF) para revisar posibles problemas de multicolinealidad, así como una verificación de valores atípicos mediante el criterio del rango intercuartílico.

En primer lugar, el promedio de los residuos fue cercano a cero, con un valor aproximado de $2,17 \times 10^{-13}$, sin embargo, la prueba de Shapiro-Wilk arrojó un p-valor menor a 0.05, por lo que se rechaza la hipótesis nula de normalidad de los residuos. A pesar de esto, los gráficos Q-Q y el histograma muestran que los residuos siguen una forma aproximadamente simétrica, aunque con desviaciones en las colas. Esto sugiere que la normalidad no se cumple de manera estricta, pero el problema no parece ser extremo visualmente.

Posteriormente, se evaluó la homocedasticidad mediante la prueba de Breusch-Pagan. El valor-p obtenido fue aproximadamente $1,2331 \times 10^{-10}$, por lo que se rechaza la hipótesis nula de igualdad de varianzas. Esto indica la presencia de heterocedasticidad en el modelo, es decir, la varianza de los residuos no se mantiene constante. Este resultado también se observa en la gráfica de residuos estandarizados contra valores ajustados, donde la dispersión de los residuos no es completamente uniforme.

En cuanto a la multicolinealidad, se calculó el VIF para cada variable explicativa. Los resultados muestran que la mayoría de las variables presentan valores VIF moderados y menores a 5, como *ANALF*, *SBASC*, *OVSDE*, *VHAC*, *OVPT*, *PO2SM* y *PL5000*. Por otro lado, las variables *GM_Alto* y *GM_Muy alto* presentan valores cercanos a 6, lo cual sugiere una posible multicolinealidad moderada asociada a las categorías del grado de

marginación. Aun así, los valores no superan el umbral común de 10, por lo que no se considera un problema severo.

En conjunto, los resultados del diagnóstico muestran que el modelo base presenta un ajuste razonable y una relación lineal clara entre los valores observados y ajustados. Sin embargo, también se identifican problemas de heterocedasticidad, falta de normalidad en los residuos y presencia de algunos valores atípicos. Por ello, aunque el modelo base es útil como primera especificación, es necesario considerar correcciones o modelos alternativos que mejoren la validez estadística.

6.2. Modelos Alternativos

La obtención del modelo óptimo no se realizó de manera arbitraria ni únicamente con base en criterios intuitivos, sino a través de un proceso iterativo de selección y evaluación econométrica. Debido a que la base de datos construida inicialmente contaba con aproximadamente 50 indicadores potenciales, se decidió no incorporar todas las variables al modelo, con el fin de respetar el principio de parsimonia y evitar problemas de sobreajuste o redundancia explicativa.

En consecuencia, se plantearon cuatro especificaciones alternativas, las cuales fueron estimadas mediante el método de Mínimos Cuadrados Ordinarios (MCO). Posteriormente, a cada modelo se le aplicaron distintas pruebas de diagnóstico para verificar el cumplimiento de los supuestos clásicos de la regresión múltiple, permitiendo así comparar su desempeño estadístico y seleccionar la especificación más adecuada para explicar el porcentaje de pobreza.

Los modelos estimados fueron los siguientes:

- Selección Stepwise: Es una alternativa computacionalmente eficiente que restringe el espacio de búsqueda. Este procedimiento comienza con el modelo nulo M_0 y añade predictores uno a uno, incorporando en cada paso únicamente a la variable que proporciona la mayor mejora adicional al ajuste. Sin embargo, al correr este algoritmo en Python frente a la base de datos con los 2,466 municipios, la estrategia automática no fue de gran ayuda y tuvo que ser descartada por completo por criterio econométrico. El modelo sugerido por el procedimiento iterativo arrojó un coeficiente de determinación perfectamente igual a uno ($R^2 = 1,00$). En la práctica, un ajuste del 100 % es un resultado artificial e inconsistente; este fenómeno evidenció un problema severo de multicolinealidad perfecta provocado por variables redundantes que construían matemáticamente la identidad de la pobreza en lugar de explicar su verdadera causalidad económica.
- Modelo Alternativo 1: Esta primera especificación se construyó tomando como base las variables socio-económicas que resultaban relevantes en la segunda base de datos, pero incorporando además las variables de carencias sociales provenientes de la primera base. La intención de este modelo fue evaluar si la combinación de indicadores de marginación, vivienda, educación, ingreso y carencias permite explicar de manera más completa las diferencias en los niveles de pobreza entre municipios.

La especificación general del modelo fue la siguiente:

$$\begin{aligned}
 pobreza_i = & \beta_0 + \beta_1 ANALF_i + \beta_2 SBASC_i + \beta_3 OVSDE_i \\
 & + \beta_4 VHAC_i + \beta_5 OVPT_i + \beta_6 PO2SM_i \\
 & + \beta_7 PL5000_i + \beta_8 carencia_servicios_basicos_i \\
 & + \beta_9 carencia_rezago_educativo_i \\
 & + \beta_{10} carencia_calidad_espacios_i \\
 & + \beta_{11} carencia_servicios_salud_i \\
 & + \beta_{12} carencia_alimentacion_i \\
 & + \gamma GM_i + u_i
 \end{aligned} \tag{1}$$

Los resultados muestran que el modelo tiene un buen ajuste, con un $R^2 = 0,830$ y un $R^2 = 0,829$. Esto indica que aproximadamente el 83 % de la variación en la pobreza municipal es explicada por las variables incluidas. Además, el estadístico F fue significativo, por lo que el conjunto de variables independientes tiene capacidad explicativa sobre la pobreza.

En términos individuales, varias variables resultaron estadísticamente significativas, como ANALF, SBASC, OVSDE, VHAC, OVPT, PO2SM, PL.5000, carencia_servicios_basicos_vivienda_porcentaje, GM_Alto,

carencia_rezago_educativo_porcentaje, carencia_calidad_espacios_vivienda_porcentaje, GM_Medio y carencia_servicios_de_salud_porcentaje. Esto sugiere que las condiciones educativas, de vivienda, ingreso, servicios básicos y marginación están relacionadas con el porcentaje de pobreza municipal.

- Modelo Alternativo 2: El segundo modelo estimado corresponde a una especificación más reducida. En este caso, se conservaron únicamente algunas variables que, desde el punto de vista económico, tienen una relación directa con la pobreza municipal: el analfabetismo, la proporción de población con ingresos de hasta dos salarios mínimos, la población en localidades menores a 5000 habitantes y las variables dicotómicas asociadas al grado de marginación.

La forma general del modelo fue:

$$\begin{aligned} pobreza_i = & \beta_0 + \beta_1 ANALF_i + \beta_2 PO2SM_i + \beta_3 PL5000_i \\ & + \gamma_1 GM_Alto_i + \gamma_2 GM_Medio_i + \gamma_3 GM_MuyAlto_i + \gamma_4 GM_Bajo_i + u_i. \end{aligned} \quad (2)$$

Los resultados muestran que el modelo mantiene un buen nivel de ajuste, con un $R^2 = 0,772$ y un $R^2_{adj} = 0,772$. Esto indica que aproximadamente el 77.2% de la variación en la pobreza municipal es explicada por las variables incluidas. Además, el estadístico F fue significativo, por lo que el modelo en conjunto tiene capacidad explicativa sobre la pobreza.

En términos individuales, todas las variables incluidas resultaron estadísticamente significativas. Las variables *ANALF* y *PO2SM* presentan coeficientes positivos, lo cual indica que mayores niveles de analfabetismo y una mayor proporción de población con ingresos bajos se asocian con mayores niveles de pobreza municipal. En particular, *PO2SM* presenta un coeficiente de 1,0741, por lo que es una de las variables con mayor peso dentro del modelo.

Por otro lado, la variable *PL5000* presenta un coeficiente negativo. Este resultado puede estar relacionado con la forma en que esta variable interactúa con el grado de marginación y con otras características territoriales de los municipios. Asimismo, las variables de grado de marginación presentan coeficientes positivos, lo que sugiere que los municipios con mayores niveles de marginación tienden a presentar porcentajes más altos de pobreza en comparación con la categoría base.

En general, este segundo modelo es más sencillo que el primero, ya que utiliza un menor número de variables y conserva únicamente indicadores clave de ingreso, educación, tamaño de localidad y marginación. Aunque su ajuste es menor que el del primer modelo, sigue explicando una proporción importante de la variación en la pobreza municipal.

- Modelo alternativo 3: El tercer modelo estimado corresponde a una especificación basada únicamente en las carencias sociales, con el objetivo de analizar qué tanto las carencias explican, por sí solas, el porcentaje de pobreza municipal.

La forma general del modelo fue:

$$\begin{aligned} pobreza_porcentaje_i = & \beta_0 + \beta_1 carencia_servicios_basicos_vivienda_porcentaje_i \\ & + \beta_2 carencia_rezago_educativo_porcentaje_i \\ & + \beta_3 carencia_calidad_espacios_vivienda_porcentaje_i \\ & + \beta_4 carencia_servicios_de_salud_porcentaje_i \\ & + \beta_5 carencia_alimentacion_nutritiva_calidad_porcentaje_i + u_i. \end{aligned} \quad (3)$$

Los resultados muestran que el modelo tiene un ajuste moderado, con un $R^2 = 0,662$ y un $R^2_{adj} = 0,661$. Esto indica que aproximadamente el 66.2% de la variación en la pobreza municipal es explicada únicamente por las variables de carencias sociales. Además, el estadístico F fue significativo, por lo que el conjunto de variables incluidas tiene capacidad explicativa sobre la pobreza.

En términos individuales, todas las variables resultaron estadísticamente significativas. Además, todos los coeficientes presentan signo positivo, lo cual es coherente con la teoría, ya que mayores niveles de carencias sociales se asocian con mayores niveles de pobreza municipal. En particular, la carencia por

rezago educativo y la carencia por servicios básicos en la vivienda presentan coeficientes relativamente altos, lo que sugiere que estas dimensiones tienen una relación importante con el nivel de pobreza.

Aunque este modelo tiene un menor nivel de ajuste que los modelos anteriores, su principal ventaja es que ofrece una interpretación más directa y sencilla, sin embargo, al excluir variables de ingreso, marginación y características territoriales, puede omitir información relevante para explicar de manera más completa la pobreza municipal.

6.3. Supuestos y estrategias de identificación

Para todos los modelos estimados se aplicaron pruebas de diagnóstico con el objetivo de verificar el cumplimiento de los supuestos de la regresión lineal múltiple. En particular, se revisó la normalidad de los residuos mediante la prueba de Shapiro-Wilk y la prueba Jarque-Bera, la homocedasticidad mediante la prueba de Breusch-Pagan, la multicolinealidad a través del cálculo del VIF y la correcta especificación funcional mediante la prueba Ramsey RESET. Los resultados completos se presentan en el (Anexo 2), a partir de esta tabla podemos llegar a las siguientes conclusiones.

En primer lugar, todos los modelos presentan evidencia de no normalidad en los residuos, ya que los valores de $\text{Prob}(\text{JB})$ son menores a 0.05 en todos los casos, esto implica que se rechaza la hipótesis nula de normalidad.

En cuanto a la homocedasticidad, la prueba de Breusch-Pagan muestra p-valores muy pequeños en los cuatro modelos, por lo que se rechaza la hipótesis nula de varianza constante, esto indica presencia de heterocedasticidad.

Respecto a la multicolinealidad, el Modelo 1 presenta el problema más importante, ya que alcanza un VIF máximo de 15.00783 y cuenta con variables con VIF alto. En contraste, el Modelo 3 muestra el mejor comportamiento en este aspecto, con un VIF máximo de 3.122. El Modelo 2 también presenta niveles aceptables de multicolinealidad, mientras que el Modelo 4, considerado como modelo base, muestra una multicolinealidad moderada, con un VIF máximo de 6.613.

Por otro lado, la prueba Ramsey RESET indica posibles problemas de especificación funcional en todos los modelos, ya que los p-valores son menores a 0.05, lo que implica que la relación entre la pobreza y algunas variables explicativas podría no estar completamente capturada mediante una forma lineal simple. En consecuencia, podrían considerarse transformaciones, interacciones o correcciones adicionales para mejorar la especificación.

Finalmente, al comparar los modelos, el Modelo 4 presenta un desempeño favorable como modelo base, ya que mantiene un alto poder explicativo, con un $R^2 = 0,820$ y un R^2 ajustado de 0,819, además de que todas sus variables resultaron estadísticamente significativas.

7. Resultados

A partir de las diferentes pruebas aplicadas a los cuatro modelos claves que fueron previamente justificados, llegamos a la conclusión de nuestro modelo base, a través también del análisis de la tabla de estadísticos (Anexo 3), donde nuestra variable dependiente es “Porcentaje de Pobreza” y nuestras variables independientes son: “ANALF”, “SBASC”, “OVSDE”, “VHAC”, “OVPT”, “PO2SM”, “PL.5000” y nuestras variables dummy “GM_Muy bajo”, “GM_Bajo”, “GM_Medio”, “GM_Alto” y “GM_Muy alto”. El modelo arroja un R^2 de 0.820 y un R^2 ajustado de 0.819, indicando que las variables explicativas incluidas logran explicar aproximadamente el 82.0 % de la variabilidad del porcentaje de pobreza por municipio.

7.1. Interpretación económica

Interpretación económica del efecto de las variables independientes, manteniendo las de más constantes.

- ANALF (Analfabetismo): El coeficiente es positivo y claramente significativo, lo que demuestra que la falta de lectoescritura en los municipios representa una barrera en los municipios, y lleva a la población a mayores tasas de pobreza.
- SBASC (Porcentaje de población de 15 años o más sin educación básica): Igualmente tiene un coeficiente positivo y significativo al 5 % de significancia, es decir, que el porcentaje de pobreza también aumenta por como los mercados laborales y las oportunidades se ven afectadas por la falta de educación básica, esto justificando también el analfabetismo.

Variable	Coefficiente	Error estándar	Estadístico t	p-valor ($P > t $)
ANALF	0.2175	0.053	4.137	0.000
SBASC	0.0723	0.026	2.785	0.005
OVSDE	-0.3089	0.041	-7.604	0.000
VHAC	0.6177	0.029	21.484	0.000
OVPT	0.2764	0.033	8.345	0.000
PO2SM	0.9076	0.027	33.685	0.000
PL.5000	-0.0838	0.008	-10.908	0.000
GM_Medio	6.1040	0.888	6.876	0.000
GM_Alto	8.6983	1.136	7.656	0.000
GM_Muy alto	5.7375	1.713	3.350	0.001
GM_Bajo	2.1782	0.700	3.113	0.002

Tabla 2: Coeficientes del Modelo de Regresión

- OVSDE (Porcentaje de ocupantes en viviendas particulares habitadas sin drenaje ni excusado): Esta variable tiene un efecto negativo sobre el porcentaje de pobreza y bastante significativo, aunque de forma teórica este signo no tendría sentido, pues por cada unidad de porcentaje que aumenta la población son drenaje ni excusado, la pobreza disminuye: sin embargo, el signo puede deberse a un efecto de multicolinealidad, por lo que captura un efecto que prácticamente no le pertenece.
- VHAC (Porcentaje de viviendas particulares con hacinamiento): Es una variable significativa con un efecto positivo en la pobreza, el hacinamiento como tal es la falta de espacio en un hogar para la cantidad de personas viviendo en ese lugar, el modelo solo es el reflejo que vivir en esas condiciones es un indicador de pobreza a nivel municipal.
- OVPT (Porcentaje de ocupantes en viviendas particulares con piso de tierra): Por cada una unidad por ciento que esta variable aumenta, la pobreza incrementa su porcentaje, en términos económicos, el hecho de que en una vivienda tengan piso con tierra, es un indicador de pobreza, pues estas familias pueden estar incluso expuestas a mayores problemas de salud, lo que implicaría un gasto.
- PO2SM (Porcentaje de población ocupada con ingresos de hasta 2 salarios mínimos): Esta variable, además de significativa, presenta un coeficiente positivo grande y su estadístico t el más grande entre todos; nos indica que la falta de ingresos es el mayor detonante de pobreza en los municipios.
- PL.5000 (Porcentaje de población que vive en localidades menores a 5000 habitantes): Tenemos un coeficiente con signo negativo para esta variable, que de forma interpretada dice que, por un aumento en las localidades pequeñas, menores a 5000 específicamente, el porcentaje de pobreza disminuye. Económicamente, pueden existir diversos factores para que ocurra esto, pues estas comunidades pueden sostenerse por trabajo interno como la agricultura, que tal vez otras zonas marginadas no tengan.
- GM (Grados de marginación): Nuestros grados de marginación tienen coeficientes bastante grandes y todos son significativos, esto solo prueba que la marginación, anidado a otros factores como los anteriores, son la mayor causa de pobreza municipal, independientemente tal vez de las condiciones laborales.

8. Validación y diagnóstico

A partir de nuestro modelo base, realizamos las pruebas para supuestos y en caso de ser necesaria la corrección de errores para tener un modelo válido y confiable.

8.1. Outliners

Decidimos hacer la prueba de outliners primero, porque queríamos comprobar si había datos con valores extremos que estuvieran afectando a nuestro modelo, es decir, si estos ejercen algún efecto sobre la línea de

regresión, detectamos valores fuera de los rangos en: ANALF(14), OVSDE(160), VHAC(1), OVPT(49), sin embargo fueron valores extremos dentro del rango calculado pero no fuera del rango de un porcentaje del 0 a 100 %, lo cual es normal, pues puede reflejar pobreza extrema en ciertos municipios, por lo que optamos por una prueba de sensibilidad para ver que tanto estaban afectando dichos valores a nuestro modelo.

8.2. Sensibilidad

En nuestra prueba de sensibilidad quisimos detectar cook (la distancia del impacto real que tiene cada municipio sobre los coeficientes), leverage (qué tan alejadas están las variables independientes de un municipio), residuos extremos (distancia entre el valor real de pobreza y el valor que el modelo predice). Con respecto a los resultados, obtuvimos los valores que son significativamente influyentes en nuestro modelo e hicimos un modelo alternativo eliminándolos. Obtuvimos la comparación de ambos modelos (Anexo 4), aquí se pudo observar que no hay cambios en los signos de los coeficientes, sin embargo, ANALF y OVSDE si tuvieron un cambio grande en los coeficientes, lo que quiere decir que las observaciones influyentes afectan, por lo que concluimos que estas variables son sensibles. A pesar de ello se decide conservar el modelo base, pues al revisar detalladamente estos valores, estos representan datos reales que no se pueden simplemente ignorar.

8.3. VIF

Una vez teniendo el modelo comprobamos multicolinealidad con los valores de VIF y obtuvimos multicolinealidad moderada y en algunos casos un poco alta, específicamente entre las variables GM_Alto y GM_Muy alto, lo cual es lógico ya que representan el extremo superior de marginación, así que redujimos el número de variables dummy, ahora solo serían GM_Alto_Total, GM_Medio, GM_Bajo_total, para así evitar categorías con comportamiento similar, lo que corrigió significativamente nuestro problema de multicolinealidad, dejando a varias cerca de 1 y otras con multicolinealidad moderada, con un modelo con todas las variables significativas y un R^2 de 0.818 (Anexo 5)

8.4. Transformaciones

Como previamente se habían comprobado supuestos como heteroscedasticidad, normalidad y especificación, y comprobamos que nuestro modelo cuenta con todos ellos, utilizamos primero una transformación Log-lineal, ya que esta ayuda a comprimir extremos, que en nuestro caso por los outliers nos favorecería, y porque mejora supuestos, sin embargo, esto no mejoró ninguno de nuestros supuestos, hizo algunas variables insignificativas como “GM_Medio”, “ANALF” y “SBASC”, incluso disminuyó nuestro R^2 a 0.745. Por lo tanto, optamos por una transformación Box-Cox, donde obtuvimos un R^2 de 0.820 y todas las variables fueron significativas, sin embargo, dado que aún con la prueba de especificación no mejoró, pues nuestro p-valor fue de 0.00522; para solucionarlo nos inclinamos por elevar algunas variables al cuadrado, ya que las relaciones entre pobreza y carencias sociales no necesariamente son lineales. Las variables fueron:

- PO2SM: El efecto de la población ocupada con ingresos de hasta dos salarios mínimos puede no ser constante. En municipios donde un porcentaje de la población que gana poco afecta la pobreza, entonces un aumento en porcentaje de esta población podría ser más significativo.
- VHAC: A medida que aumenta el porcentaje de viviendas hacinadas, las condiciones de vida pueden resultar afectadas y disminuir la calidad de vida, haciendo el porcentaje de pobreza más intenso.
- OVSDE: Un mayor nivel mayor de viviendas con falta de drenaje y excusados puede intensificar la pobreza, ya que se relaciona con condiciones sanitarias, rezago habitacional y menor acceso a servicios básicos.
- OVPT: Parecido a la variable anterior, un aumento en el nivel de malas condiciones en la vivienda, pueden afectar gravemente en la pobreza.

Al correr nuestro modelo, nuestra R^2 mejoró siendo este de 0.838, sin embargo, aun teníamos error de especificación y ahora nuestra multicolinealidad de algunas variables había aumentado, por lo que consideramos incluir interacciones en nuestro modelo, ya que algunas variables pueden tener un efecto diferente en conjunto, que de forma individual no. Estas fueron:

- PL.5000*OVPT: Dado que el efecto de vivir en viviendas con piso de tierra puede ser distinto en municipios con menor a 5000 habitantes a una localidad más urbanizada.
- VHAC*OVPT: Además también puede haber un efecto cuando una gran cantidad de personas viven en la misma habitación, teniendo piso de tierra, por diferentes causas, tanto de salud como económicas.

Habiendo probado este modelo también tuvimos un resultado parecido, pero con mayor éxito, un R^2 mejor de 0.835, todas variables significativas e incluso una mejora en el VIF, con un valor máximo de 4.6, pero aún sin éxito en la especificación, sin embargo, con una mejora significativa en el p-valor de nuestra prueba RESET, pues fue de 0.04, aun así, nos estábamos acercando. Por lo que tomamos la decisión de ir probando estas interacciones con algunas de nuestras variables cuadráticas, todo claro desde el principio con las variables centralizadas ya que trabajamos con porcentajes. Obtuvimos el modelo con las siguientes variables: “GM_Medio”, “GM_Alto_Total”, “ANALF”, “SBASC”, “OVSDE1”, “VHAC”, “OVPT1”, “PO2SM”, “PL.5000”, “PL5000_OVPT”, “VHAC_OVPT” y como términos cuadráticos “OVPT²”, “OVSDE²”. Así corregimos el error de especificación con éxito, con un p-valor de 0.007 y con multicolinealidad moderada. (Anexo 6)

8.5. Normalidad de los residuos

Después de dichas modificaciones a nuestro modelo, aún no logramos mejora en la normalidad de los errores, sin embargo, sabemos que esto es normal en muestras que son demasiado grandes, por lo que no nos centramos en resolver esa prueba.

8.6. Heteroscedasticidad

Por último, desde el diagnóstico de nuestro modelo tuvimos heteroscedasticidad, comprobada con la prueba de BP, con un p-valor de $3,762933 \times 10^{-13}$, utilizamos Mínimos cuadrados ponderados (WLS), dado que podrían reducir el peso a los datos con varianza alta y darles mayor peso a los valores de varianza estable, sin embargo, la prueba de Breusch-Pagan continuó mostrando evidencia de varianza no constante (Anexo 7). Por ello, se decidió utilizar errores estándar robustos HC3 para realizar la inferencia estadística.

9. Modelo final

Nuestro modelo final fue un modelo Box-Cox con errores estándar robustos HC3, Esto permite que las pruebas t, los valores p y los intervalos de confianza sean más confiables Debido a que el modelo final se estimó usando una transformación Box-Cox sobre la variable dependiente, los coeficientes se interpretan sobre la escala transformada de Y (Anexo 8). Por lo tanto, nuestras variables son:

- PO2SM: Tiene un efecto positivo y sigue siendo la variable con mayor impacto en el modelo. Si en un municipio aumenta el porcentaje de personas que ganan salarios muy bajos, la pobreza transformada se aumenta significativamente.
- ANALF: El rezago educativo es un factor clave y constante, que mueve el efecto de la pobreza hacia arriba, dejando claro su impacto en la pobreza.
- SBASC: No terminar la primaria o secundaria también incrementa la pobreza de forma estadísticamente significativa, aunque su impacto por cada unidad es menor que el del analfabetismo.

También se encuentran las variables que pueden tener efecto diferente cuando interactúan con otras variable o incluso cuando su relación no es lineal.

- VHAC: Su coeficiente de forma individual es muy alto, pero tiene un cambio de efecto cuando se agrega la interacción con el piso de tierra ($VHAC * OVPT = -0,0368$). Esto significa que el hacinamiento es un factor para elevar la pobreza, pero su impacto marginal disminuye levemente en municipios donde las casas además ya sufren por tener pisos de tierra.
- OVPT: Su coeficiente base es positivo. Su término al cuadrado tiene un p-valor de 0.138, lo que significa que no es estadísticamente significativo. Sin embargo, su interacción con la población de localidades pequeñas ($PL5000 * OVPT = +0,0097$) sí es muy significativa. Esto demuestra que tener piso de tierra aumenta

la pobreza en todos lados, pero este impacto es mucho más dañino y severo en los municipios rurales y aislados.

- OVSDE: Su coeficiente base es de efecto negativo, pero su término al cuadrado es positivo y muy significativo. Esto dibuja una parábola o curva: al principio, en municipios con niveles bajos de falta de drenaje, el impacto parece no importar o ir hacia abajo; pero cuando la falta de drenaje se vuelve muy alta y grave en un municipio, el término al cuadrado empieza a sumar mucha pobreza.
- PL.5000: Su coeficiente si solo tiene un efecto negativo en la pobreza, es decir que en lugares donde existe menos población no precisamente es un indicador de pobreza; pero si esa población rural empieza a acumular viviendas con pisos de tierra (PL5000*OVPT), la pobreza en esas zonas rurales se incrementa de inmediato.
- Variables dummy (Grado de Marginación): Ambos coeficientes son altamente significativos. Esto nos dice que pertenecer a un municipio clasificado con un Grado de Marginación Alto aumenta el indicador de pobreza transformado, así como, estar en marginación Media le suma 3.98 unidades. Esto nos da una conclusión bastante lógica: a mayor marginación en el municipio, mayor es la pobreza base que calcula el modelo.

10. Conclusión

10.1. Hallazgos clave

Los resultados muestran que la pobreza está relacionada con factores educativos, económicos, de vivienda y de marginación. Variables como el analfabetismo y la población sin educación básica completa tienen sentido dentro del modelo, ya que un menor nivel educativo puede limitar las oportunidades laborales de la población y afectar sus ingresos.

También las variables relacionadas con vivienda fueron relevantes, como el hacinamiento, las viviendas con piso de tierra y la falta de drenaje o excusado. Estas condiciones reflejan carencias que afectan directamente la calidad de vida de las personas y que pueden estar asociadas con mayores niveles de pobreza. Además la variable de población ocupada con ingresos de hasta dos salarios mínimos fue una de las más importantes, lo que confirma que el bajo ingreso sigue siendo un factor central para explicar la pobreza municipal. Otra cosa importante fue la marginación, ya que los municipios con mayores rezagos tienden a presentar mayores niveles de pobreza. Con respecto a las interacciones y términos cuadráticos, estos nos ayudaron a que el modelo captara mejor que la relación entre pobreza y carencias sociales no siempre es lineal; es decir, algunas variables pueden tener un efecto diferente dependiendo del nivel en el que se encuentren o de cómo se relacionen con otras variables.

10.2. Implicaciones económicas/financieras

Los resultados muestran que la pobreza no depende solamente del ingreso, aunque este sí es un factor muy importante. También está relacionada con la educación, la vivienda, los servicios básicos y el nivel de marginación. Por lo que una política pública que solo busque aumentar los ingresos de la población podría no ser suficiente si no se atienden también otros rezagos.

Desde el punto de vista económico los municipios con mayor rezago educativo pueden tener más dificultades para que su población acceda a mejores empleos y salarios. Si las personas no cuentan con educación básica o presentan analfabetismo, es más probable que tengan menos oportunidades en el mercado laboral y que se mantengan en condiciones de bajos ingresos.

De igual forma las malas condiciones de vivienda pueden afectar otros aspectos de la vida de las personas. Vivir en hacinamiento, con piso de tierra o sin servicios básicos puede afectar la salud, el bienestar y la productividad de los hogares. Esto puede generar más gastos para las familias y hacer más difícil que mejoren su situación económica.

Por eso, el modelo puede servir como una herramienta para identificar en qué factores se deberían enfocar más los recursos públicos. Los resultados sugieren que sería importante invertir no solo en apoyos económicos, sino también en educación, vivienda, infraestructura y servicios básicos, especialmente en municipios con mayores niveles de marginación.

10.3. Limitaciones del análisis

Una limitación es que el modelo presentó heteroscedasticidad. Aunque se probaron otras alternativas, al final se decidió utilizar errores estándar robustos HC3, ya que esto permite que los valores t, los p-valores y los intervalos de confianza sean más confiables.

Otra limitación es que se utilizó una transformación Box-Cox en la variable dependiente. Esto hace que los coeficientes no se interpreten directamente como cambios simples en el porcentaje de pobreza, sino sobre la variable transformada. Por ello fue importante llegar a nuestras conclusiones e interpretaciones de forma cuidadosa.

En conclusión, a pesar de tener las limitaciones que mencionamos previamente, el modelo en general, funciona para explicar de forma completa el comportamiento de la pobreza en los municipios y puede servir como base para pensar en políticas públicas más centralizadas sobre el verdadero problema en nuestra sociedad, saber en que lugares apoyar más y en que variables prestar más atención.

11. Referencias

Consejo Nacional de Evaluación de la Política de Desarrollo Social. (s. f.). Índice de rezago social 2020. <https://www.coneval.org.mx/Medicion/IRS/Paginas/IndiceRezagoSocial2020.aspx>

Consejo Nacional de Población. (s. f.). Índices de marginación 2020. Gobierno de México. <https://www.gob.mx/conapo/documentos/indices-de-marginacion-2020-284372>

Villanueva, D. (2021, 31 de enero). Persiste rezago regional en servicios a viviendas. La Jornada. <https://www.jornada.com.mx/notas/2021/01/31/economia/persiste-rezago-regional-en-servicios-a-viviendas/>

Consejo Nacional de Evaluación de la Política de Desarrollo Social. (s. f.). Pobreza a nivel municipio 2010-2020. <https://www.coneval.org.mx/Medicion/Paginas/Pobreza-municipio-2010-2020.aspx>

Instituto Nacional de Estadística y Geografía. (2025, agosto). Pobreza multidimensional 2024. https://www.inegi.org.mx/contenidos/desarrollosocial/pm/doc/pm_presentacion2024.pdf

Instituto Mexicano para la Competitividad. (2021, 15 de diciembre). Una mirada a la pobreza municipal file:///C:/Users/ariad/AppData/Local/Packages/5319275A.WhatsAppDesktop_v1g1gvanyjgm/LocalState/sessions/B7B21/Pobreza-municipal20211512.pdf

Secretaría de Bienestar. (s. f.). Informes anuales sobre la situación de pobreza y rezago social. Gobierno de México. <https://www.gob.mx/bienestar/documentos/informe-anual-sobre-la-situacion-de-pobreza-y-rezago-social>

12. Anexos

- Anexo 1. Resumen Modelos Rendimiento Académico

Métrica / Prueba	Modelo Fase 1	Modelo Fase 2
R^2	0.070	0.015
R^2 ajustada	0.017	-0.004
AIC	307.4	1585
BIC	334.6	1606
Prueba F	0.234	0.558
VIF	Máx. 1.156309 Variables con VIF moderado: 8	Máx. 1.302055 Variables con VIF moderado: 5
Heteroscedasticidad	p-value BP: 0.35918783	p-value BP: 0.0000
Prob(JB)	0.00680	0.0000
Variables significativas	3/8	1/5

Anexo 2: Modelos alternativos Rendimiento Académico:

Anexo 3: Tabla de estadísticos

Métrica / Prueba	Modelo 1	Modelo 2	Modelo 3	Modelo 4	Modelo 5	Modelo 6
R^2	0.029	0.014	0.023	0.016	0.022	0.018
R^2 ajustada	0.004	-0.004	0.004	0.004	0.006	0.009
AIC	2137	2138	2135	2134	2134	2131
BIC	2172	2165	2162	2153	2157	2146
Prueba F	p-value: 0.312	p-value: 0.580	p-value: 0.286	p-value: 0.259	p-value: 0.216	p-value: 0.120
Prob(JB)	0.00	0.00	0.00	0.00	0.00	0.00
No. de observaciones	329	329	329	329	329	329
Variables del modelo	8	6	6	4	5	3
Variables significativas	0/8	0/6	1/6	0/4	0/5	0/3

Métrica / Prueba	Modelo 1	Modelo 2	Modelo 3	Modelo 4
R^2	0.830	0.772	0.662	0.820
R^2 ajustada	0.829	0.772	0.661	0.819
AIC	17,880	18,590	19,560	18,020
BIC	17,980	18,630	19,590	18,090
Prueba F	0.00	0.00	0.00	0.00
VIF	Máx. 15.00783 Variables con VIF moderado: 5 Variables con VIF grave: 2	Máx. 4.960034 Variables con VIF moderado: 4 Variables con VIF grave: 0	Máx. 3.122 Variables con VIF moderado: 2 Variables con VIF grave: 0	Máx. 6.6313 Variables con VIF moderado: 8 Variables con VIF grave: 2
Heteroscedasticidad	p-value BP: $2,5020 \times 10^{-9}$	p-value BP: $1,4775 \times 10^{-17}$	p-value BP: $2,43018 \times 10^{-32}$	p-value BP: $2,11678 \times 10^{-10}$
Prob(JB)	$5,07 \times 10^{-24}$	$1,54 \times 10^{-21}$	$1,38 \times 10^{-05}$	$1,27 \times 10^{-29}$
Especificación	p-value RESET: 0.01047	p-value RESET: $1,685 \times 10^{-09}$	p-value RESET: $7,0702 \times 10^{-24}$	p-value RESET: 0.003124
Variables significativas	13/16	7/7	5/5	11/11

Variable	Modelo original	Modelo sin influyentes	Diferencia
const	-34.080464	-36.627488	-2.547023
ANALF	0.217524	0.142670	-0.074855
SBASC	0.072286	0.071485	-0.000800
OVSDE	-0.308950	-0.560280	-0.251330
VHAC	0.617719	0.656460	0.038742
OVPT	0.276370	0.296463	0.020093
PO2SM	0.907611	0.950071	0.042460
PL.5000	-0.083783	-0.089182	-0.005399
GM_Medio	6.104030	5.950124	-0.153906
GM_Alto	8.698328	8.549702	-0.148625
GM_Muy alto	5.737458	5.991677	0.254219
GM_Bajo	2.178210	2.068688	-0.109522

Anexo 4: Comparación de modelos con datos influyentes y sin ellos

Anexo 5: VIF modelo con variables fusionadas

Índice	Variable	VIF
0	const	122.610551
1	GM_Medio	1.991962
2	GM_Bajo_Total	4.705013
3	ANALF	4.121743
4	SBASC	3.589351
5	OVSDE	1.227041
6	VHAC	2.506124
7	OVPT	2.051146
8	PO2SM	2.674961
9	PL.5000	1.879895

Anexo 6: Estadísticos y coeficientes de la transformación Box-Cox (λ óptimo = 1.112)

Estadísticos	Valor	Estadísticos	Valor
R^2	0.820	AIC	$2,023 \times 10^4$
R^2 ajustado	0.820	BIC	$2,029 \times 10^4$
Estadístico F	1247.	Prob (Estadístico F)	0.00
Jarque-Bera (JB)	95.455	Prob(JB)	$1,87 \times 10^{-21}$

Variable	Coeficientes	Error Estándar	t	p-valor ($P > t $)
const	-52.6340	3.254	-16.173	0.000
GM_Medio	-3.9572	1.036	-3.818	0.000
GM_Bajo_Total	-11.2452	1.276	-8.812	0.000
ANALF	0.2729	0.078	3.491	0.000
SBASC	0.1532	0.040	3.844	0.000
OVSDE	-0.5344	0.062	-8.685	0.000
VHAC	0.9917	0.044	22.547	0.000
OVPT	0.3769	0.047	8.033	0.000
PO2SM	1.4365	0.041	35.354	0.000
PL.5000	-0.1200	0.011	-10.495	0.000

Anexo 7: Comparación de resultados de las pruebas BP con pesos ponderados y normales

	Prueba	LM statistic	LM p-value	F statistic	F p-value
0	BP residuos normales	121.350812	$1,088602 \times 10^{-19}$	9.762070	$3,241102 \times 10^{-20}$
1	BP residuos ponderados	276.640034	$1,826065 \times 10^{-51}$	23.832795	$9,317472 \times 10^{-55}$

Anexo 8: Modelo final OLS con Errores Estándar Robustos (HC3)

Variable	Coficiente (coef)	Error Estándar (std err)	Estadístico t	p-valor (P> t)
const	-59.7022	3.108	-19.209	0.000
GM_Medio	3.9863	1.061	3.758	0.000
GM_Alto_Total	6.0297	1.350	4.465	0.000
ANALF	0.3174	0.075	4.232	0.000
SBASC	0.1697	0.040	4.217	0.000
OVSDE1	-0.8078	0.096	-8.410	0.000
VHAC	1.1274	0.047	23.825	0.000
OVPT1	0.7272	0.085	8.576	0.000
PO2SM	1.3459	0.048	28.279	0.000
PL5000	-0.0722	0.012	-5.819	0.000
PL5000_OVPT	0.0097	0.001	6.605	0.000
VHAC_OVPT	-0.0368	0.004	-8.253	0.000
OVPT2	-0.0068	0.005	-1.483	0.138
OVSDE2	0.0149	0.002	6.133	0.000

Estadístico Global	Valor	Estadístico Global	Valor
R^2	0.837	AIC	$2,000 \times 10^4$
R^2 ajustado	0.836	BIC	$2,008 \times 10^4$
Estadístico F	1325.	Prob (Estadístico F)	0.00
Jarque-Bera (JB)	131.537	Prob(JB)	$2,74 \times 10^{-29}$
No. Observaciones	2466	Durbin-Watson	1.604